

GitHub: <https://github.com/mariberteli/AD1/tree/main>

O *dataset* escolhido reúne notícias sobre o mercado de cultura pop, englobando os setores de filmes, séries e *games*.

• Um exemplo de POS Tagging de uma sentença do texto.

A, Lenda, de, Aang, :, DET, PROP, N, ADP, PROP, N, PUNCT, ,, o, Lenda, de, Aang, :, O, Último, Mestre, do, Ar, |, DET, P
ROP, N, PROP, N, ADP, PROP, N, PROP, N, ,, o, Último, Mestre, de
o, Ar, |, Vazamento, liga, alerta, na, Paramount, ,, NOUN, VERB, VERB, ADP, PROP, N, PUNCT, liga
alerta, vazamento, ligar, alertar, em
o, Paramount, ,, Estúdio, teme, novo, vazamento, NOUN, VERB, ADJ, NOUN, teme, estúdio, temer, novo, vazamen
to

• Um exemplo de NER de uma sentença do texto.

0, Digimon Story Time Stranger, MISC, 0, 27, Nintendo Switch, MISC, 50, 65, 1, Nintendo
Switch, MISC, 14, 29, Switch, MISC, 35, 41

• Os gráficos e tabelas da análise de dados do texto gerados pelos notebooks.

Quantidade de stopwords: 416

```
df_dataset.sample(5)
```

	id	sentencas	documento
9	10	['Spider-Noir ', 'Equipe fala sobre o "desafi...	Spider-Noir Equipe fala sobre o "desafio dob...
28	29	['Castlevania: Belmont's Curse Jogo ganha no...	Castlevania: Belmont's Curse Jogo ganha novo...
6	7	['Euphoria Zendaya brigou com Sam Levinson q...	Euphoria Zendaya brigou com Sam Levinson qua...
3	4	['X-Men '97 Veja novo pôster e vídeo com mut...	X-Men '97 Veja novo pôster e vídeo com mutan...
10	11	['A Namorada Ideal vai ganhar 2ª temporada no ...	A Namorada Ideal vai ganhar 2ª temporada no Pr...

```
df_dataset_pos.sample(5)
```

id		pos_documento
7	8	[[['Delphi', 'I', 'Ator', 'de', 'Pinguim', 'en...
19	20	[[['Homem-Aranha', 'mutante', 'ganha', 'imagem...
25	26	[[['Resident', 'Evil', 'Veronica', 'I', 'Produ...
21	22	[[['God', 'of', 'War', ':'], ['PROPN', 'PROPN'...
12	13	[[['Doctor', 'Who', 'deve', 'ficar', 'fora', '...

```
df_dataset_ner.sample(5)
```

id		ner_documento
27	28	[[0, []], [1, [['Uncharted', 'MISC', 0, 9]]], ...
13	14	[[0, [['Doctor Who Especial de Natal', 'MISC'...
20	21	[[0, [['Auto da Compadecida Omelete', 'MISC'...
14	15	[[0, [['Octavia', 'PER', 39, 46]]], [1, [['Spe...
29	30	[[0, [['Amsterdam', 'LOC', 5, 14], ['Assassin'...

```
# Especifica o(s) campo(s) indexado(s) e faz uma cópia da lista indexada
```

```
df_dataset_indexado = df_dataset.set_index(["id"])
```

```
df_dataset_indexado.head()
```

sentencas		documento
id		
1	[Law & Order:, SVU tem showrunner mulher pela ...	Law & Order: SVU tem showrunner mulher pela pr...
2	[Colman Domingo fala sobre importância dos fig...	Colman Domingo fala sobre importância dos figu...
3	[O Vampiro Lestat 2º episódio ganha pôster i...	O Vampiro Lestat 2º episódio ganha pôster in...
4	[X-Men '97 Veja novo pôster e vídeo com muta...	X-Men '97 Veja novo pôster e vídeo com mutan...
5	[Criador de Gravity Falls critica aquisição da...	Criador de Gravity Falls critica aquisição da ...

```
# Especifica o(s) campo(s) indexado(s) e faz uma cópia d  
df_dataset_pos_indexado = df_dataset_pos.set_index(["id"]  
df_dataset_pos_indexado.head()
```

```
# Especifica o(s) campo(s) indexado(s) e faz um  
df_dataset_ner_indexado = df_dataset_ner.set_in  
df_dataset_ner_indexado.head()
```

pos_documento	
id	
1	[[[Law, &, Order, :, [PROPN, PROPN, PROPN, PU...
2	[[[Colman, Domingo, fala, sobre, importância, ...
3	[[[O, Vampiro, Lestat, , 2º, episódio, ganha,...
4	[[[X-Men, ', 97, , Veja, novo, pôster, e, víd...
5	[[[Criador, de, Gravity, Falls, critica, aquis...

		ner_documento
id		
1	[[0, [['Law & Order', 'ORG', 0, 11]]], [1, ['...	
2	[[0, [['Colman Domingo', 'PER', 0, 14]]], [1, ...	
3	[[0, [['O Vampiro Lestat', 'MISC', 0, 16]]], [...	
4	[[0, [['X-Men', 'ORG', 0, 5]]], [1, [['Disney+...	
5	[[0, [['Gravity Falls', 'LOC', 11, 24], ['Warn...	

```
sentenca_token: ['|']
id
19
sentencas      [Game of Thrones, |, Kit, Harington precisou d...
documento      Game of Thrones | Kit Harington precisou de re...
Name: 18, dtype: object
sentenca_token: ['Kit']
id
19
sentencas      [Game of Thrones, |, Kit, Harington precisou d...
documento      Game of Thrones | Kit Harington precisou de re...
Name: 18, dtype: object
sentenca_token: ['Novo']
id
28
sentencas      [Novo, Uncharted está em desenvolvimento, diz ...
documento      Novo Uncharted está em desenvolvimento, diz jo...
Name: 27, dtype: object
Total de Sentenças              : 70
Total de Sentenças com uma palavra : 3
Total de palavras                : 732
Total de palavras distintas      : 408
Total de palavras sem stopwords  : 515
Total de tokens BERT             : 941
Total de documentos abaixo 512   : 30
Total de entidades reconhecidas   : 90
Total de palavras desconhecidas repetidas : 148
Total de palavras desconhecidas sem repetições : 129
Total de sentenças com 2 ou mais loc verbos : 19 sendo 27.14% do total de sentenças
Total de sentenças com Verbos(VERB) : 30 sendo 42.86% do total de sentenças
Total de sentenças com Verbos(VERB e AUX) : 30 sendo 42.86% do total de sentenças
Total de sentenças com substantivos(NOUN) : 30 sendo 42.86% do total de sentenças
Total de sentenças com VERB, AUX e NOUN : 30 sendo 42.86% do total de sentenças
```

dfstats_documentos_pos.sample(5)

	id	sentenca	palavra	pos
613	25	0	Nintendo	PROPN
647	27	0	por	ADP
52	3	0	estética	NOUN
577	23	1	Serafitas	PROPN
379	15	2	Prime	PROPN


dfstats_documentos_ner.sample(5)

	id	sentenca	entidade	classe
44	17	0	Batman: Parte 2 Rumor	MISC
41	16	0	Elle Série de Legalmente	MISC
84	29	0	Castlevania: Belmont's Curse Jogo	MISC
13	6	0	The Pitt Atriz	MISC
52	19	0	Game of Thrones	MISC



	pos	ADJ	ADP	ADV	AUX	CCONJ	DET	NOUN	NUM	PRON	PROPN	PUNCT	SCONJ	SYM	VERB
count		46	115	10	21	12	33	148	5	5	187	61	7	1	81
unique		36	24	8	9	2	15	110	5	4	134	7	3	1	62
top		novo	de	não	será	e	o	série	97	se		.	que	%	ganha
freq		4	24	2	6	11	6	12	1	2	17	21	4	1	5

classe	LOC	MISC	ORG	PER
count	6	45	13	26
unique	6	41	11	24
top	Gravity Falls	Prime Video	Paramount	Lara Croft
freq	1	4	2	2



	id	qtdesentencas	qtdepalavras	qtdetokensbert	qtdepalavrassemstopword	qtdelocverbo	qtdeverbo	qtdeverboaux	qtde substantivo	qtdeverboauxsubstantivo	qtdepalavrasdesconhecidas	qtdener
count	30.00	30.00	30.0	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00
mean	15.50	2.33	24.4	31.37	17.17	2.67	2.70	3.40	4.93	8.33	4.93	3.00
std	8.80	0.84	4.8	6.23	3.47	1.06	1.09	1.28	1.96	2.52	1.80	0.95
min	1.00	1.00	16.0	21.00	11.00	1.00	1.00	2.00	2.00	5.00	2.00	1.00
25%	8.25	2.00	21.0	26.50	15.00	2.00	2.00	2.25	4.00	6.25	3.25	2.00
50%	15.50	2.00	24.0	31.00	17.00	3.00	3.00	3.00	4.50	8.00	5.00	3.00
75%	22.75	3.00	27.0	34.75	19.00	3.00	3.00	4.00	6.00	10.00	6.00	4.00
max	30.00	5.00	36.0	44.00	24.00	6.00	6.00	7.00	10.00	15.00	9.00	5.00



	PRON	VERB	PUNCT	DET	NOUN	AUX	CCONJ	ADP	PROPN	ADJ	ADV	NUM	SCONJ	SYM	SPACE	INTJ
count	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.0	30.0
mean	0.17	2.70	2.03	1.10	4.93	0.70	0.40	3.83	6.23	1.53	0.33	0.17	0.23	0.03	0.0	0.0
std	0.38	1.09	1.16	0.92	1.96	0.75	0.67	1.44	2.46	1.31	0.55	0.38	0.57	0.18	0.0	0.0
min	0.00	1.00	0.00	0.00	2.00	0.00	0.00	1.00	2.00	0.00	0.00	0.00	0.00	0.00	0.0	0.0
25%	0.00	2.00	1.00	0.25	4.00	0.00	0.00	3.00	4.00	1.00	0.00	0.00	0.00	0.00	0.0	0.0
50%	0.00	3.00	2.00	1.00	4.50	1.00	0.00	4.00	6.00	1.00	0.00	0.00	0.00	0.00	0.0	0.0
75%	0.00	3.00	3.00	1.75	6.00	1.00	1.00	5.00	8.00	2.75	1.00	0.00	0.00	0.00	0.0	0.0
max	1.00	6.00	5.00	3.00	10.00	3.00	2.00	6.00	11.00	4.00	2.00	1.00	2.00	1.00	0.0	0.0



	LOC	MISC	ORG	PER
count	30.00	30.0	30.00	30.00
mean	0.20	1.5	0.43	0.87
std	0.41	1.2	0.77	1.01
min	0.00	0.0	0.00	0.00
25%	0.00	1.0	0.00	0.00
50%	0.00	1.0	0.00	1.00
75%	0.00	2.0	1.00	1.00
max	1.00	4.0	3.00	3.00



```

de => 26
. => 21
| => 18
: => 17
' => 12
série => 12
da => 11
e => 11
em => 9
no => 9
do => 9
temporada => 7
para => 7
: => 6
ao => 6
na => 6
o => 6
será => 6
0 => 5
ganha => 5


```

```



Switch => ['Sw', '##itch'] => 4
Noir => ['No', '##in'] => 3
Spider => ['Sp', '##ider'] => 3
veja => ['ve', '##ja'] => 3
Creed => ['Cre', '##ed'] => 2
Croft => ['Cro', '##ft'] => 2
Doctor => ['Doc', '##tor'] => 2
Levinson => ['Le', '##vin', '##son'] => 2
Veronica => ['Ver', '##oni', '##ca'] => 2
aborda => ['aborda', '##r'] => 2
mitologias => ['mitologia', '##s'] => 2
mongol => ['mon', '##gol'] => 2
pôster => ['pôs', '##ter'] => 2
showrunner => ['show', '##ru', '##n', '##ner'] => 2
1666 => ['166', '##6'] => 1
2028 => ['202', '##8'] => 1
AMC => ['AM', '##C'] => 1
Aang => ['Aa', '##ng'] => 1
Amon => ['Am', '##on'] => 1
Amsterdam => ['Amster', '##dam'] => 1



```



	id	sentenca	qtdepalavras	qdetokensbert	qtdepalavrassemstopword	qtdelocverbo	qtdeverbo	qtdeverboaux	qtde substantivo	qtdeverboauxsubstantivo	qtdepalavrasdesconhecidas	qtdener
count	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00
mean	16.13	0.81	10.46	13.44	7.36	1.14	1.16	1.46	2.11	3.57	2.11	1.29
std	8.56	0.89	5.32	6.99	3.68	0.89	0.93	1.19	1.43	2.29	1.57	0.87
min	1.00	0.00	1.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
25%	10.00	0.00	6.00	7.25	5.00	1.00	1.00	1.00	1.00	3.00	1.00	1.00
50%	17.00	1.00	10.00	13.00	7.00	1.00	1.00	1.00	2.00	3.00	2.00	1.00
75%	22.75	1.00	13.00	18.00	9.75	2.00	2.00	2.00	3.00	5.00	3.00	2.00
max	30.00	4.00	27.00	33.00	18.00	4.00	4.00	6.00	6.00	10.00	7.00	4.00





	PRON	VERB	PUNCT	DET	NOUN	AUX	CCONJ	ADP	PROPN	ADJ	ADV	NUM	SCONJ	SYM	SPACE	INTJ
count	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.00	70.0	70.0
mean	0.07	1.16	0.87	0.47	2.11	0.30	0.17	1.64	2.67	0.66	0.14	0.07	0.10	0.01	0.0	0.0
std	0.26	0.93	0.88	0.63	1.43	0.55	0.42	1.22	2.06	0.81	0.35	0.26	0.39	0.12	0.0	0.0
min	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.0	0.0
25%	0.00	1.00	0.00	0.00	1.00	0.00	0.00	1.00	1.00	0.00	0.00	0.00	0.00	0.00	0.0	0.0
50%	0.00	1.00	1.00	0.00	2.00	0.00	0.00	1.50	2.00	0.00	0.00	0.00	0.00	0.00	0.0	0.0
75%	0.00	2.00	1.00	1.00	3.00	0.75	0.00	2.75	4.00	1.00	0.00	0.00	0.00	0.00	0.0	0.0
max	1.00	4.00	4.00	2.00	6.00	2.00	2.00	5.00	8.00	3.00	1.00	1.00	2.00	1.00	0.0	0.0














	LOC	MISC	ORG	PER
count	70.00	70.00	70.00	70.00
mean	0.09	0.64	0.19	0.37
std	0.28	0.83	0.39	0.62
min	0.00	0.00	0.00	0.00
25%	0.00	0.00	0.00	0.00
50%	0.00	0.00	0.00	0.00
75%	0.00	1.00	0.00	1.00
max	1.00	4.00	1.00	3.00







	id	qtdepalavras	qtdetokensbert	qtdepalavrasjanela3	qtdepalavrasjanela5	qtdetokenbertjanela3	qtdetokenbertjanela5
count	70.00	70.00	70.00	70.00	70.00	70.00	70.00
mean	16.13	10.46	13.44	22.94	24.37	29.41	31.17
std	8.56	5.32	6.99	6.29	4.61	8.34	6.12
min	1.00	1.00	1.00	4.00	16.00	6.00	21.00
25%	10.00	6.00	7.25	20.00	21.00	24.25	26.00
50%	17.00	10.00	13.00	23.50	24.00	30.00	31.00
75%	22.75	13.00	18.00	27.00	27.00	34.75	34.75
max	30.00	27.00	33.00	36.00	36.00	44.00	44.00

	id	qtde sentencas	qtdepalavras	qtdetokensbert	totalpalavrasjanela3	totalpalavrasjanela5	totaltokenbertjanela3	totaltokenbertjanela5
count	30.00	30.00	30.0	30.00	30.00	30.00	30.00	30.00
mean	15.50	2.33	24.4	31.37	53.53	56.87	68.63	72.73
std	8.80	0.84	4.8	6.23	16.85	22.99	22.14	28.17
min	1.00	1.00	16.0	21.00	20.00	20.00	25.00	25.00
25%	8.25	2.00	21.0	26.50	44.50	44.50	57.00	57.00
50%	15.50	2.00	24.0	31.00	53.00	53.00	67.50	67.50
75%	22.75	3.00	27.0	34.75	64.50	66.00	79.50	82.00
max	30.00	5.00	36.0	44.00	87.00	135.00	123.00	155.00

